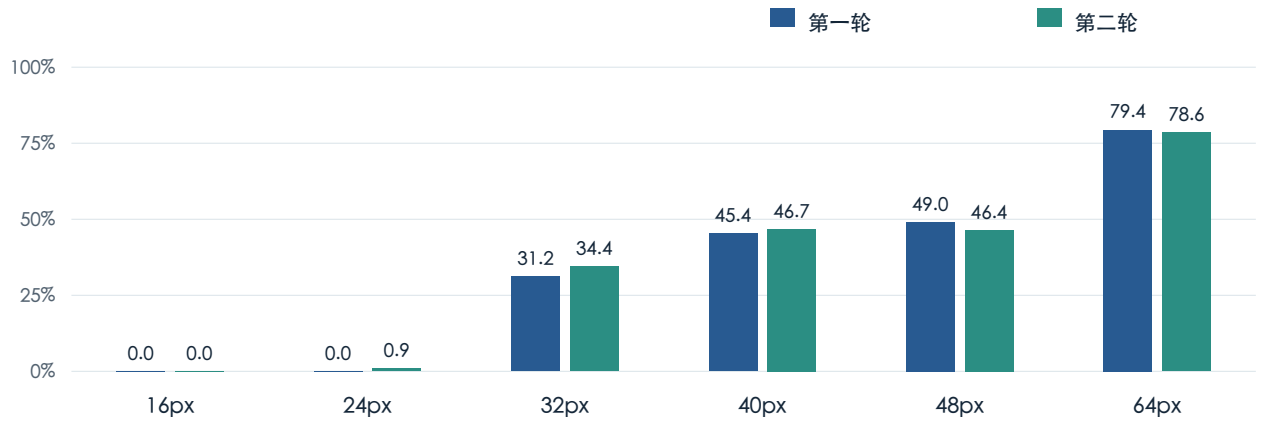
GPT Advanced 两轮结果对比

实验1 / 实验2 · 192个同条件配对 · 6字号 × 32级灰度

结论：总体规律接近，逐条件输出仍存在波动。

第一轮34.15%，第二轮34.50%，净增0.35个百分点。均值接近不代表逐条一致，也不构成统计等效证明。



逐字号结果

字号	第一轮	第二轮	差值/百分点	平均绝对差/百分点
16px	0.00%	0.00%	0.00	0.00
24px	0.00%	0.91%	+0.91	0.91
32px	31.16%	34.44%	+3.28	4.03
40px	45.38%	46.72%	+1.34	4.66
48px	49.00%	46.38%	-2.63	9.44
64px	79.38%	78.56%	-0.81	2.63

正确数分别为6557/19200和6624/19200。第二轮40px-g23采用最终复核后的67分，未使用旧汇总34.51%。

一致性与波动

不同“一致”指标表达不同事实

指标	结果
是否存在目标字符匹配一致	185/192（96.35%）
得分完全相同	107/192，其中94个是两轮均为0
分差不超过5 / 10个百分点	160/192 / 173/192
平均绝对差	全体3.61个百分点；剔除共同零分后7.07个百分点
同条件得分相关系数	约0.966；不是一致率，也不证明文字输出相同

48px均值接近，但条件内波动最大

48px的平均绝对差为9.44个百分点。下面三条说明上涨与下跌会互相抵消，净均值差无法表达全部波动。

条件	第一轮	第二轮	变化/百分点
48px-g09	61	0	-61
48px-g15	65	0	-65
48px-g28	19	80	+61

g09第二轮输出天气预报词句，g15答非所问，按既定规则计0；g28第二轮保留了更长的目标形似序列，得分提高。原始回复见两轮正式工作簿的完整回复页签。

口径与边界

两轮均没有零编辑全对的回复。16px两轮全0，24px仍基本不识读，32px起出现较多部分转写，64px最好。每条件只有两次正式观测；提示词、追问和采集时间并非逐条一致，服务端模型未确认，不能据此给出可靠失败概率或稳定阈值。

数据来源与复算

第1轮：26-11-01/exp1-gpt-advanced/GPT_Advanced_实验结果01.xlsx

SHA-256前12位：4e2bf394c6bf；逐条件记录见上述正式结果表。

第2轮：26-11-02/exp2-gpt-advanced/GPT_Advanced_实验结果02.xlsx

SHA-256前12位：91449b9584bc；逐条件记录见上述正式结果表。

原始工作簿保持不变；脚本只读“实验结果”中的整数正确数，以字号和灰度配对，校验“完整回复”参考串一致。每图100字符，每字号32个条件。